



Universidad Externado de Colombia

Departamento de Matemáticas

Programa de Ciencia de Datos

Informe - Fase 1

Comprensión del Artículo y Planteamiento

Focalize K-NN: an imputation algorithm for time series datasets

Curso: Machine Learning 1

Semestre: Cuarto semestre

Docente: Carolina Torres Lozano

Integrantes del equipo

Gabriel Castro gabriel.castro2@est.uexternado.edu.co

Karen Torres karen.torres6@est.uexternado.edu.co

Bogotá D.C., Colombia
19 de Agosto de 2026

Índice

1. Comprensión y sustentación del artículo	3
1.1. Problema abordado por el artículo	3
1.2. Modelo empleado	3
1.3. Supuestos principales	3
1.3.1. Correlación entre predictores	3
1.3.2. Correlación temporal	3
1.3.3. Patrones de los datos faltantes	3
1.4. Resultados reportados por los autores	3
1.5. Limitaciones del artículo	4
1.5.1. Datos Faltantes Artificiales	4
1.5.2. Ecalabilidad del Modelo	4
1.5.3. Desempeño	4
2. Planteamiento del problema	4
2.1. Pregunta de investigación	4
2.2. Tipo de tarea	4
2.3. Variable objetivo	5
2.4. Relevancia en el contexto colombiano o latinoamericano	5
2.5. Objetivos	5
3. Estrategia de datos	5
3.1. Fuente de los datos	6
3.2. Caracterización del conjunto de datos previsto	6
3.3. Variable objetivo y predictores	6
4. Plan de modelamiento y línea base	6
4.1. Modelos candidatos	6
4.2. Métrica principal de evaluación	6
4.3. Estrategia de validación	7
4.4. Modelo de línea base	7
Referencias	8

1 Comprensión y sustentación del artículo

1.1 Problema abordado por el artículo

En el artículo, los autores proponen un método de imputación de datos faltantes con el objetivo de reducir la pérdida de información en series de tiempo. Se centran principalmente en series de tiempo meteorológicas y energéticas, resaltando los problemas estratégicos derivados de tomar decisiones basadas en tendencias temporales incompletas.

1.2 Modelo empleado

Se propone un modelo K-NN Focalizado (FKNN), modelo derivado del imputador K-NN. Este modelo propone mejoras frente al imputador tradicional, dado que usa las relaciones que tienen los atributos (*features*) y los rezagos temporales (*lags*) con las series de tiempo que presentan datos faltantes.

1.3 Supuestos principales

El estudio realizado por los autores parte de varios supuestos, asociados principalmente a las relaciones entre las variables independientes y la estructura de los datos faltantes:

1.3.1. Correlación entre predictores

Existe correlación entre las variables con datos faltantes y los demás *features*, de modo que estas relaciones se puedan utilizar y aporten suficiente información para imputar las series de tiempo.

1.3.2. Correlación temporal

Los autores usan *lags* de distinta magnitud como predictores de los datos faltantes, suponiendo así que registros de observaciones pasadas contienen información útil para estimar los valores faltantes de la serie de tiempo.

1.3.3. Patrones de los datos faltantes

Los datos faltantes presentan dos principales patrones: *overlap* y *disjoint*. A su vez, estos patrones son representativos de patrones de faltantes reales.

Overlap missing pattern: Ocurre cuando varios sensores fallan de manera simultánea, sea por interrupciones o fallos eléctricos, en un período de tiempo determinado. Esto provoca bloques de valores nulos con poca información de datos vecinos.

Disjoint missing pattern: Ocurre cuando los sensores fallan en diferentes momentos. Los valores faltantes resultantes no fueron provocados por el mismo evento o error de medición exacto, por lo que existe información relevante de datos vecinos.

1.4 Resultados reportados por los autores

El principal resultado del estudio refiere a la estructura de los datos faltantes y su impacto en el desempeño del modelo. En *overlap missing patterns*, el modelo no presenta mejoras significativas frente al imputador K-NN tradicional. Además, conforme el porcentaje de faltantes aumenta (a

partir del 50 %), técnicas como imputación por media o por mediana se presentan más efectivas. Por otro lado, evaluando el modelo con series de tiempo que presentan *disjoint missing patterns*, los autores observan un mejor desempeño del modelo FKNN propuesto, destacando su efectividad con proporciones altas de datos faltantes.

1.5 Limitaciones del artículo

1.5.1. Datos Faltantes Artificiales

Los datos faltantes de las series de tiempo usadas en el artículo son sintéticos. Para poder evaluar el desempeño del modelo, al ser un problema supervisado, se requieren los valores originales para calcular el error de imputación, por lo que estos datos pueden no representar a completitud todos los mecanismos de faltantes en series de tiempo reales. Los mismos autores mencionaron que el desempeño del modelo se ve afectado según el patrón de valores nulos.

1.5.2. Escalabilidad del Modelo

El imputador propuesto se deriva directamente del imputador K-NN tradicional, por lo que hereda las limitaciones propias de este modelo, como lo es la escalabilidad. K-NN tiene problemas a la hora de tratar con bases de datos muy grandes, pues aunque la cantidad de variables que usa el modelo para imputar cada serie de tiempo se limita a las más correlacionadas, esto no tiene en cuenta la cantidad de registros en cada *feature*.

1.5.3. Desempeño

FKNN no siempre presenta mejoras significativas en comparación con otros métodos de imputación, sino que dependiendo del patrón y la cantidad de los datos faltantes el modelo tiene resultados distintos. Especialmente con patrones *overlap*, el modelo no presenta un desempeño destacable frente al K-NN tradicional, además, conforme aumenta la cantidad de faltantes, técnicas más sencillas que no requieren regresión obtienen mejores resultados.

2 Planteamiento del problema

Lo que queremos resolver a partir del artículo es cómo imputar de la forma más precisa los datos climáticos que se pierden en una estación meteorológica. En la vida real, cuando falla un sensor, no se pierde un solo dato aislado, sino bloques enteros de información. En ocasiones la falla afecta a varios sensores al tiempo (*overlap*) y otras veces a uno solo (*disjoint*).

2.1 Pregunta de investigación

¿Qué tan efectivo es el algoritmo FKNN para recuperar datos meteorológicos perdidos en estaciones especializadas cuando enfrentamos fallas masivas en los sensores, y en qué momento su precisión empieza a caer en comparación con el K-NN tradicional?

2.2 Tipo de tarea

Imputación de series temporales mediante regresión. Estimaremos variables cuantitativas y continuas, esto va a consistir en predecir un valor numérico a partir de su relación con otras variables.

2.3 Variable objetivo

En lugar de fijar una única variable objetivo, el proceso se adapta dinámicamente a cualquier variable que presente datos faltantes. Así, los predictores cambian según la variable a imputar en cada momento, seleccionando la información del resto de sensores de la estación junto con sus datos pasados.

2.4 Relevancia en el contexto colombiano o latinoamericano

En nuestro país y en la región, las estaciones de monitoreo del clima sufren muchísimo por pérdidas masivas de datos. Basta con que se vaya la luz en el campo, falle el internet rural o se dañe un sensor y quede semanas sin mantenimiento para que queden huecos gigantes en los registros. Si logramos rellenar estos vacíos con algoritmos inteligentes, evitamos perder información de registros históricos y podemos usar esa información para cosas clave en la región, como gestionar el riego en los cultivos o prevenir pérdidas por heladas y sequías.

2.5 Objetivos

Objetivo general

Reproducir y evaluar el comportamiento del algoritmo Focalize K-NN (FKNN) para la imputación de datos faltantes en series de tiempo meteorológicas, analizando su desempeño frente al K-NN tradicional y métodos de línea base en escenarios con distintos patrones de pérdida.

Objetivos específicos

- Implementar el algoritmo FKNN aprovechando la correlación entre variables secundarias y sus rezagos temporales para estimar los valores perdidos de la variable objetivo.
- Simular diferentes patrones de pérdida de datos en la serie temporal, evaluando tanto fallas simultáneas en múltiples sensores (*overlap*) como fallas independientes en momentos distintos (*disjoint*).
- Analizar la degradación del rendimiento del algoritmo al someterlo a gradientes de severidad de datos faltantes, probando proporciones desde un 10 hasta más de un 50 de vacíos en los registros.
- Comparar la precisión del modelo FKNN contra algoritmos de distancia convencionales (K-NN) y métricas simples de línea base (media/mediana), utilizando métricas de evaluación de regresión como el Error Cuadrático Medio (MSE).

3 Estrategia de datos

En el presente proyecto se hará uso de bases de datos reales colombianas, centradas en el contexto meteorológico. Se decidió seguir esta metodología dada la disponibilidad de datos de este tipo en los territorios colombianos, y el interés por preservar la información relevante para caracterizar observaciones y tendencias climatológicas reales en nuestro país.

3.1 Fuente de los datos

Se eligió una base de datos real colombiana que contiene información meteorológica del municipio de Aranzazu, en el departamento de Caldas. Contiene registros de los años 2018 y 2019. La base de datos es proveída por la Alcaldía de Aranzazu y está alojada en la página oficial de *Datos Abiertos de Colombia*.

3.2 Caracterización del conjunto de datos previsto

El *dataset* contiene 19190 registros y 20 variables. De las 20 variables, 18 son numéricas, sin embargo están codificadas como *str* a pesar de representar mediciones meteorológicas (humedad, temperatura, velocidad del viento, etc), esto dado que se usan comas "," como indicador de decimales. Por otro lado, la variable *time* es una variable de tiempo que representa la fecha y hora a la que se realizó la medición, crucial para el objetivo de nuestro proyecto. Por último, la variable *Wind Direction* indica la dirección del viento mediante abreviaturas de los puntos cardinales e intercardinales (S, N, E, W, SE, NW, etc.).

3.3 Variable objetivo y predictores

Dado el planteamiento del imputador no contamos con una variable objetivo principal. El algoritmo de imputación FKNN selecciona las series de tiempo con datos faltantes, y predice los valores faltantes de manera iterativa: elige la primer serie de tiempo con faltantes (la cual fungirá como *target*), predice su valor con la información aportada por los *features* y *lags* más correlacionados a esta (estos son los predictores), y luego continua con la siguiente serie de tiempo. Dado esto, no queda establecido un *target* específico para el modelo de regresión, sino que va cambiando, y por tanto sus predictores también. Por consiguiente, podríamos decir que nuestro *target* son todas las series de tiempo con datos faltantes, las cuales claro, son de datos meteorológicos e irán variando según los experimentos, pues la generación de valores faltantes se realiza artificialmente.

4 Plan de modelamiento y línea base

Como preparación de los datos, se organizarán cronológicamente los registros y se transformarán las variables a formatos numéricos cuando sea necesario.

4.1 Modelos candidatos

Los métodos que se compararán con el Focalize K-NN serán el imputador K-NN estándar, la Regresión Lineal, y predictores basados en la media y la mediana. Los últimos tres modelos servirán como modelos de línea base. Por su parte, el K-NN estándar servirá como método de referencia, ya que realiza la imputación utilizando la similitud entre observaciones disponibles. Por su parte, FKNN incorpora información adicional de la estructura temporal de las series y de las relaciones entre variables.

4.2 Métrica principal de evaluación

La métrica principal será el MAE, debido a que permite medir directamente la diferencia promedio entre los valores reales y los valores imputados. Como los valores faltantes son generados artificialmente sobre una base de datos originalmente completa, se conocen los valores reales que

fueron ocultados. Por lo tanto, después de realizar la imputación, es posible comparar cada valor imputado con su valor original y calcular el error.

4.3 Estrategia de validación

Para evaluar los métodos de imputación se partirá de un conjunto de datos completo. Sobre esta base se generarán artificialmente diferentes patrones de valores faltantes. De esta manera, se conocen de antemano los valores originales que fueron ocultados y es posible evaluar objetivamente qué tan bien cada método logra recuperarlos. Para evitar fuga de información, los métodos de imputación utilizarán únicamente la información disponible en el escenario correspondiente. Los valores que fueron ocultados artificialmente no estarán disponibles para el algoritmo durante la imputación y solamente se utilizarán posteriormente para comparar las predicciones con los valores reales.

4.4 Modelo de línea base

La línea base del proyecto estará conformada por métodos sencillos de imputación, siguiendo la metodología utilizada en el artículo de referencia. En particular, se considerarán el reemplazo de los valores faltantes por la media y el reemplazo por la mediana, ya que estos métodos se encuentran entre los que obtuvieron mejores resultados en los experimentos presentados por los autores. Además, se usará la Regresión Lineal, que aunque obtuvo el peor desempeño, servirá como referencia predictiva.

Referencias

- Alcaldía de Aranzazu, Caldas. (2021). *Datos meteorológicos Aranzazu*. Portal de Datos Abiertos de Colombia. https://www.datos.gov.co/dataset/Datos-meteorol-gicos-Aranzazu/nqj3-4xmv/about_data
- Almeida, A., Brás, S., Sargento, S., & Pinto, F. C. (2024). Focalize K-NN: an imputation algorithm for time series datasets. *Pattern Analysis and Applications*, 27(39). <https://doi.org/10.1007/s10044-024-01262-3>