Universidad Externado de Colombia

Departamento de Matemáticas

Programa de Ciencia de Datos

Informe - Fase 2

Datos, Modelamiento y Validación

Focalize K-NN: an imputation algorithm for time series datasets

---

Curso: Machine Learning 1

Semestre: Cuarto semestre

Docente: Carolina Torres Lozano

Integrantes del equipo

Gabriel Castro	gabriel.castro2@est.uexternado.edu.co
Karen Torres	karen.torres6@est.uexternado.edu.co

Bogotá D.C., Colombia
24 de Octubre de 2026

Índice

1. Consolidación de los datos **3**
1.1. Datos reales y calidad . . . 3
1.2. Tramos continuos y particiones . . . 3
1.3. Simulación de faltantes y verificación . . . 4

2. Flujo reproducible sin fuga de datos **4**

3. Entrenamiento y comparación de modelos **4**

4. Validación, métricas e interpretación preliminar **5**
4.1. Estrategia y métricas . . . 5
4.2. Resultados . . . 6
4.3. Análisis del mejor modelo . . . 7

1 Consolidación de los datos

1.1 Datos reales y calidad

Trabajamos con 19.190 registros reales de la estación de Aranzazu (2018-2019) con 20 columnas. Lo único simulado son los huecos: se abren sobre datos reales para comparar lo imputado con lo verdadero, como en Almeida et al. (2024). Tras la limpieza de la Tabla 1 quedan 12 variables numéricas. Quitamos la presión relativa por su correlación idéntica (1,00) con la absoluta, dejando 11 variables modeladas. Las lluvias acumuladas no se modelan porque son sumas; solo se usa la lluvia por hora. Escalamos antes de medir distancias por el cambio de escalas (Sección 2).

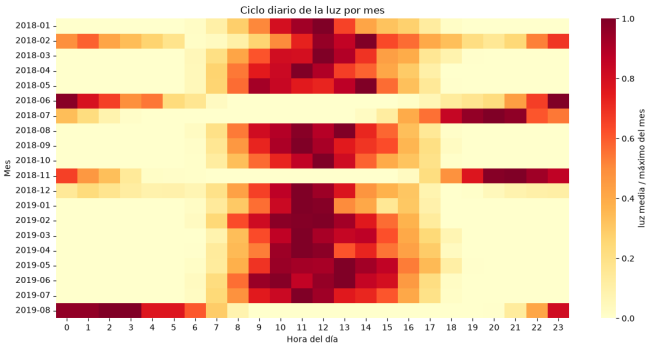
Tabla 1: Estado de calidad de los datos y tratamiento aplicado.

Problema	**Hallazgo**	**Tratamiento**
Números como texto	14 columnas con coma decimal y punto de miles	Se convirtieron a tipo numérico
Fechas en tres formatos	Tres formatos mezclados en los 19.190 registros	Se leyeron según su formato; no hay fechas vacías ni repetidas
Dirección del viento	3 valores con guiones -- (0,02 %)	Se pasaron a nulos; la variable no es numérica y salió del modelo
`UVI`	Toda la columna vale 0	Se eliminó por completo
Valores imposibles	485 filas (2,53 %) con temperatura $>$ 40 °C y presiones fuera de rango (relativa $>$ 1,100 hPa, absoluta $<$ 700 hPa); 1 lluvia por hora $>$ 100 mm y 2 luces $>$ 200,000 lux	Se pasaron a nulos (fila completa en las 485; solo la celda en las otras 3). El chequeo final no halló valores absurdos

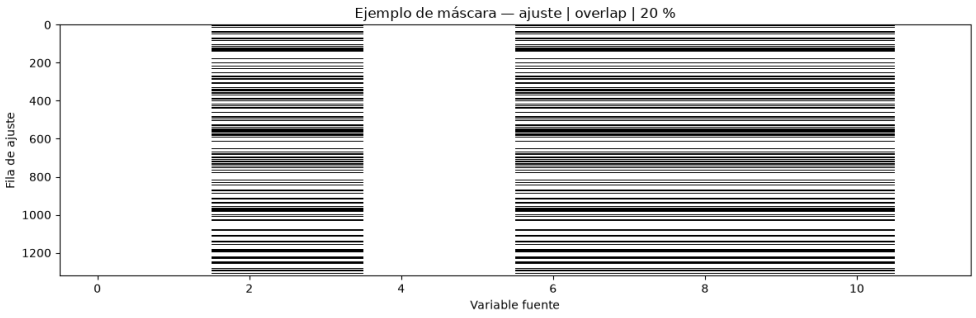
1.2 Tramos continuos y particiones

Buscamos tramos continuos sin saltos mayores a 95 minutos: del 21 de agosto al 30 de septiembre de 2018 (1.933 filas) y del 1 de mayo al 20 de junio de 2019 (2.415 filas), regularizados a intervalos de 30 minutos. Son pocos tramos porque el resto de la serie tiene huecos largos y filas dañadas.

Detectamos picos de luz nocturnos por desajuste del reloj (Figura 1a). Si entre las 7:00 p.m. y las 4:59 a.m. hay más de 5 lux, descartamos la noche entera (280 filas de 2018 y 560 de 2019, es decir, 14 y 28 noches de 20 filas). Como esta regla es fija, revisa fila por fila y no aprende de los datos, se aplica antes de dividir. Las noches borradas dejan huecos de 10 horas, por eso los rezagos se calculan dentro de cada tramo continuo y nunca cruzan una noche borrada (Sección 3).



(a) Luz media por hora y mes



(b) Máscara overlap con 20 % (negro = oculto)

Figura 1: (a) La luz debe concentrarse al mediodía, lo que justifica el filtro. (b) Ejemplo de falla simultánea en tres equipos.

Dividimos cronológicamente: 2018 se parte en entrenamiento (80 %, 1.322 filas, del 21 de agosto al 21 de septiembre) y validación (20 %, 331 filas, del 21 al 30 de septiembre), y 2019 queda como prueba externa (1.855 filas). Esto evita que el modelo vea el futuro y le exige generalizar a otra época del año. También tiene un costo: el entrenamiento cubre unos 27 días y la prueba es de mayo-junio, así que un error mayor en 2019 puede venir del cambio de época y no solo del modelo.

1.3 Simulación de faltantes y verificación

Imitamos los patrones **overlap** (varios equipos fallan a la vez) y **disjoint** (fallan por separado). Agrupamos las 12 columnas en seis equipos de medición (interior, termohigrómetro, barómetro, anemómetro, pluviómetro y luz), porque las mediciones de un mismo aparato comparten el hardware y es natural que fallen juntas. Es una decisión de diseño nuestra, no un dato de la estación. Combinamos 1, 3 o 6 equipos afectados, bloques de 1 hora a 7 días y 5 % a 50 % de datos ocultos, con semillas fijas. En disjoint cada equipo sortea sus bloques por separado y puede haber un cruce accidental, por lo que lo tratamos como patrón desfasado y no como garantía de cero cruces.

La verificación confirmó que el porcentaje oculto varió máximo 1,89 puntos del objetivo (tolerancia de 2), que las máscaras coinciden con los datos y que los bloques no cruzan los bordes. Los escenarios imposibles (como bloques de 7 días en validación) se omitieron, dejando 790 escenarios en validación, 1.170 en prueba y 1.820 en validación cruzada.

2 Flujo reproducible sin fuga de datos

Hay fuga si el modelo aprende usando datos de validación o prueba (Kaufman et al., 2012). Para evitarlo usamos un `Pipeline` de scikit-learn (Pedregosa et al., 2011) con escalador Min–Max y el imputador, y todo se ajusta solo con entrenamiento (Tabla 2). Para elegir hiperparámetros usamos validación cruzada temporal (`TimeSeriesSplit` de 2 pliegues expansivos dentro del entrenamiento, con 442 y 882 filas de ajuste y 440 de evaluación), donde el ajuste siempre precede a la evaluación (Bergmeir & Benítez, 2012). La validación 2018 solo sirvió para comparar modelos ya ajustados, y la prueba 2019 todavía no se ha usado. El código se ejecuta en orden con semillas fijas.

Tabla 2: Etapas del proceso y control de fuga de información.

N.º	Etapa	Se ajusta con	Por qué no hay fuga
1	Filtro de noches y división cronológica	Regla fija y orden temporal	La regla no aprende; validación y prueba son posteriores al entrenamiento
2	Máscaras de faltantes	Semillas independientes	Se ocultan celdas en copias y el valor real se guarda aparte
3	Escalado Min–Max	Solo entrenamiento	Los límites no ven validación ni prueba
4	Selección de variables y rezagos (F-KNN)	Solo entrenamiento	Las correlaciones se calculan solo en entrenamiento
5	Modelo de imputación	Solo entrenamiento	Promedios y vecinos provienen del entrenamiento
6	Evaluación final	Celdas ocultas	El dato real se compara solo al final del proceso

3 Entrenamiento y comparación de modelos

Imputar es un problema de regresión. Usamos KNN y regresión lineal, descartando clasificadores. La línea base usa media, mediana y moda de la Fase 1 (Tabla 3). Las variables de apoyo siguen reglas físicas (por ejemplo el punto de rocío solo se predice desde su origen).

Tabla 3: Modelos comparados y sus configuraciones.

Modelo	Cómo imputa	Hiperparámetros
Media, mediana, moda	Asigna un valor fijo por variable sin otras variables (línea base)	Sin parámetros
KNN	Promedia los k vecinos más cercanos usando hasta 8 variables	$k \in \{2,3,5,7,9,11,13,15,19\}$; pesos uniformes o por distancia
Regresión lineal iterativa	Aplica Ridge variable por variable durante 5 pasadas, quitando predictores con VIF > 10	$\alpha = 1$ fijo (sin ajustar)
F-KNN (del artículo)	KNN con variables donde $\lvert\rho\rvert \geq \tau$ (Spearman, máx. n) y hasta 2 rezagos escogidos entre 1 h, 24 h, 48 h y 168 h	$k \in \{3,5,7,9,11,15\}$, $\tau \in \{0{,}5; 0{,}6\}$, $n \in \{3,5\}$

Ajustamos los hiperparámetros con la validación cruzada de entrenamiento. En KNN el R^2 medio sube de 0,068 con $k = 7$ a 0,096 con $k = 13$, y de ahí a $k = 19$ solo gana 0,007 (frente a una desviación de 0,47) (Figura 2).

Elegimos $k = 13$ porque la curva ya está plana y un k mayor suaviza más; el artículo eligió $k = 9$ con otros datos. También comparamos pesos uniformes y por distancia con $k = 13$: los uniformes dieron un R^2 algo mayor (0,096 frente a 0,087) y un MSE algo menor (0,0326 frente a 0,0330), como en el artículo, así que usamos pesos uniformes. La diferencia es pequeña. Para F-KNN probamos 24 combinaciones con 2 semillas, confirmamos las tres mejores con 10 semillas y elegimos $k = 15$, $\tau = 0{,}5$ y $n = 3$, que tuvo el mejor R^2 en la exploración (0,209); con $\tau = 0{,}6$ ninguna combinación pasó de 0,169. Frente a KNN, F-KNN duplica el R^2 medio (0,196 frente a 0,096) y baja el MSE un 14 % (Tabla 4), pero con una desviación cercana a 0,5 entre escenarios esto es una tendencia y no una prueba.

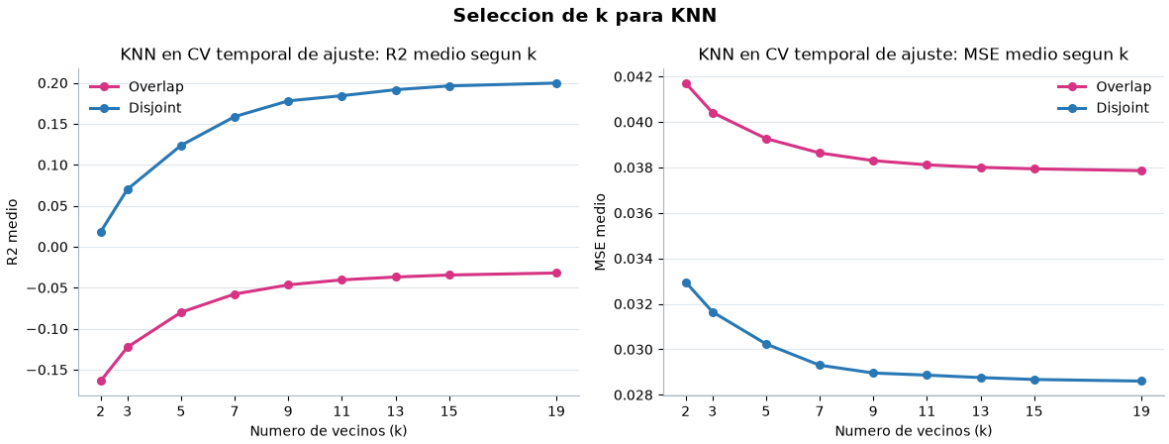


Figura 2: KNN en validación cruzada: R^2 y MSE según k.

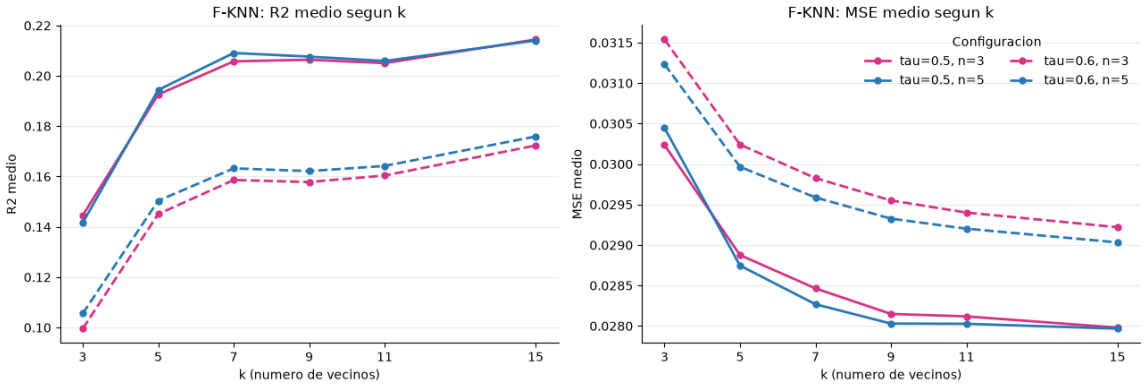


Figura 3: Búsqueda inicial de hiperparámetros F-KNN

Tabla 4: Resultados en validación cruzada de entrenamiento (1.820 escenarios).

Modelo	R^2 promedio	Desv. estándar	MSE promedio
KNN $k = 9$	0,0842	0,5016	0,0329
KNN $k = 13$ (elegido)	0,0962	0,4843	0,0326
KNN $k = 19$	0,1029	0,4719	0,0325
F-KNN $k = 7$, $\tau = 0{,}5$, $n = 3$	0,1907	0,4811	0,0286
F-KNN $k = 9$, $\tau = 0{,}5$, $n = 3$	0,1882	0,5135	0,0282
F-KNN $k = 15$, $\tau = 0{,}5$, $n = 3$ (elegido)	0,1961	0,5103	0,0280

4 Validación, métricas e interpretación preliminar

4.1 Estrategia y métricas

Ajustamos los modelos con todo el entrenamiento y los probamos en validación 2018 (790 escenarios con la misma máscara). Usamos R^2 por variable en celdas ocultas y MSE normalizado por el rango de entrenamiento para comparar sin importar las unidades (Chicco et al., 2021). El R^2 compara cada modelo con predecir el promedio de lo oculto, por eso es estricto y puede ser negativo, incluso en las líneas base. Evaluamos los seis porcentajes (5, 10, 20, 30, 40 y 50 %): la Tabla 5 resume el más bajo, uno medio y el más alto, y la Figura 4 los muestra todos.

4.2 Resultados

Tabla 5: Validación 2018: R^2 por porcentaje de faltantes y MSE medio. Mejor valor en negrita.

	Disjoint				Overlap			
Modelo	5 %	20 %	50 %	MSE	5 %	20 %	50 %	MSE
Media	−1,026	−0,102	−0,050	0,0329	−3,401	−0,147	−0,069	0,0318
Mediana	−0,676	−0,126	−0,105	0,0356	**−2,315**	−0,148	−0,109	0,0342
Moda	−0,946	−0,606	−0,561	0,0521	−2,424	−0,517	−0,547	0,0494
KNN ($k = 13$)	−0,093	0,317	0,253	0,0173	−2,837	**0,111**	0,122	0,0239
Lineal	−0,270	0,312	0,236	0,0168	−2,949	0,017	0,115	0,0249
F-KNN	**−0,022**	**0,385**	**0,299**	**0,0138**	−2,767	0,103	**0,130**	**0,0230**

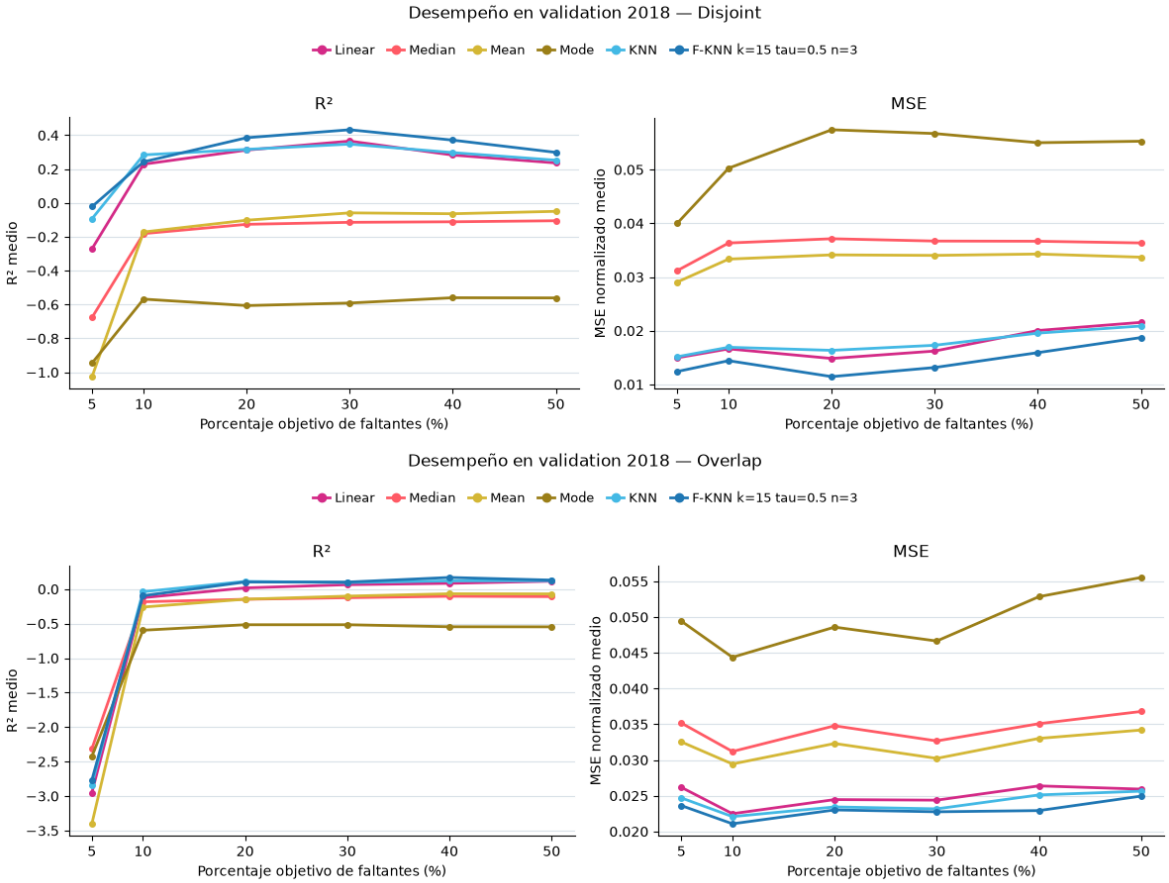


Figura 4: Desempeño en validación 2018: disjoint (arriba) y overlap (abajo).

Con 20 % o más de faltantes, KNN, lineal y F-KNN superan a las líneas base (Tabla 5, Figura 4), y la moda es la peor. Con 5 % ningún modelo mejora a la línea base de forma clara: en disjoint todos tienen R^2 negativo y en overlap la mediana (−2,315) queda mejor que KNN (−2,837) y F-KNN (−2,767). Estos valores tan negativos no son errores grandes: con 5 % se ocultan pocas celdas y lo oculto casi no varía, así que cualquier error pequeño dispara el R^2. Un escenario de F-KNN con 3 días y una sola variable oculta dio R^2 de −10,6 con un MSE de apenas 0,0004. Por eso con 5 % leemos el MSE y no sacamos conclusiones con el R^2.

F-KNN reduce el MSE un 58 % frente a la media en disjoint y un 28 % en overlap. En fallas desfasadas (disjoint) tiene el menor MSE (0,0138 frente a 0,0173 de KNN). En números concretos, con 20 % de faltantes en disjoint F-KNN explica cerca del 39 % de la variación de lo oculto (R^2 de 0,385), mientras que la media queda por debajo de cero (−0,102). En fallas simultáneas (overlap) la ventaja casi desaparece: KNN gana con 20 % (0,111 frente a 0,103) y F-KNN con 50 % (0,130 frente a 0,122), lo que sugiere que F-KNN ayuda más cuando los equipos no fallan al mismo tiempo. La ventaja en disjoint (R^2 de 0,385 frente a 0,317 con 20 %) es menor que la variación entre escenarios (Tabla 6), y F-KNN tiene el peor caso (−1,515 frente a −0,617). La leemos como tendencia, no como diferencia comprobada.

Comparación con el artículo. Nuestra réplica confirma cuatro resultados de Almeida et al. (2024): F-KNN rinde más en disjoint que en overlap, su mejora sobre KNN es pequeña, el umbral $\tau = 0{,}5$ funciona mejor que 0,6 y, en disjoint, el error sube con el porcentaje de faltantes desde 20 % (MSE de F-KNN de 0,0115 con 20 % a 0,0187 con 50 %). Difiere en el mejor k (13 frente a 9, porque nuestra curva se aplana más tarde) y en el tamaño del R^2 (0,1 a 0,4 frente a 0,94-0,98). Esa diferencia viene de los datos: el artículo usa series más numerosas (24 y 140) y largas (de uno a cinco años), mientras que nosotros tenemos una sola estación, 11 variables y 27 días de entrenamiento, y medimos el R^2 solo en celdas ocultas y por variable. Con tan poca redundancia y tan poca historia, es esperable explicar menos variación.

Tabla 6: Variabilidad del R^2 entre escenarios (media ± desviación estándar [mínimo]).

	Disjoint		**Overlap**	
Modelo	20 % (90 esc.)	50 % (50 esc.)	20 % (60 esc.)	50 % (50 esc.)
KNN ($k = 13$)	0,317 ± 0,206 [−0,617]	0,253 ± 0,055 [0,112]	0,111 ± 0,304 [−1,335]	0,122 ± 0,203 [−0,751]
Lineal	0,312 ± 0,321 [−1,235]	0,236 ± 0,075 [0,110]	0,017 ± 0,747 [−5,394]	0,115 ± 0,212 [−0,751]
F-KNN	0,385 ± 0,367 [−1,515]	0,299 ± 0,115 [−0,049]	0,103 ± 0,442 [−2,474]	0,130 ± 0,226 [−0,751]

4.3 Análisis del mejor modelo

La alta variabilidad (Tabla 6) indica que la mejora de F-KNN es una señal favorable pero no definitiva hasta ver la prueba de 2019. En overlap 50 % el mínimo (−0,751) es igual en los tres modelos, lo que apunta a un mismo escenario difícil para todos y no a una falla de un modelo.

Variables relevantes: Con $\tau = 0{,}5$ (primer pliegue de validación cruzada), temperatura y humedad exteriores tienen 5 variables disponibles con $|\rho| \geq 0{,}5$, viento y ráfaga tienen 4, y temperatura y humedad interiores y luz tienen 3. Presión, lluvia por hora y punto de rocío no tienen ninguna y dependen solo de sus rezagos. F-KNN usa como máximo 3 variables de apoyo.

Errores e implicaciones: Como los faltantes se simulan por equipo, la Tabla 7 muestra el error por equipo. F-KNN mejora a KNN sobre todo en el termohigrómetro (R^2 de 0,397 frente a 0,267 y MSE de 0,0168 frente a 0,0228), y un poco en el anemómetro y el barómetro; KNN gana en el equipo interior y en la luz. En el pluviómetro ningún modelo mejora a la media: el MSE es muy bajo (0,0034 a 0,0036) pero el R^2 es negativo, lo que indica que casi no hay variación que explicar. El barómetro tampoco supera claramente a la media, aunque los rezagos acercan a F-KNN a cero (−0,003 frente a −0,111 de KNN). Así, la ventaja global de F-KNN viene principalmente del termohigrómetro, el equipo con más variables correlacionadas disponibles. Los peores casos aparecen en overlap y con pocos datos ocultos. F-KNN conviene cuando los equipos fallan por separado y hay variables correlacionadas disponibles; si todo falla a la vez, no mejora a KNN.

Limitaciones: Contamos con pocos días de entrenamiento y validación (sin bloques de 7 días en validación), prueba de otra época del año, regresión lineal con α fijo y agrupación por equipos como supuesto de diseño. El paso final será evaluar 2019 y medir el error por variable.

Tabla 7: Validación 2018: desempeño por equipo de medición, en escenarios con 20 % o más de faltantes.

	R^2			**MSE normalizado**		
Equipo	Media	KNN	F-KNN	Media	KNN	F-KNN
Interior	−0,051	0,310	0,250	0,0303	0,0187	0,0209
Termohigrómetro	−0,062	0,267	0,397	0,0402	0,0228	0,0168
Barómetro	−0,326	−0,111	−0,003	0,0463	0,0379	0,0353
Anemómetro	−0,020	0,151	0,175	0,0210	0,0170	0,0166
Pluviómetro	−0,313	−0,380	−0,532	0,0034	0,0036	0,0036
Luz	−0,025	0,285	0,179	0,0388	0,0257	0,0304

Declaración sobre el uso de Inteligencia Artificial

Durante el desarrollo de este informe y la implementación del modelo, **utilizamos** las siguientes herramientas de apoyo tecnológico bajo nuestra supervisión directa:

- **ChatGPT (OpenAI, 2026):** Empleado como apoyo en la depuración conceptual, estructuración formal del documento en LaTeX y revisión de sintaxis general.
- **GitHub Copilot (GitHub, 2026):** Utilizado como asistente de autocompletado y sugerencia de fragmentos de código repetitivos en Python para el procesamiento de series de tiempo.
- **Control de Versiones (Git/GitHub):** La evolución del código fuente fue registrada sistemáticamente mediante *commits* en un repositorio centralizado para garantizar la reproducibilidad.

La validación experimental y la interpretación analítica de los resultados y la autoría íntegra del contenido científico recaen exclusivamente sobre nosotros como autores del documento.

Referencias

Alcaldía de Aranzazu, Caldas. (2021). *Datos meteorológicos Aranzazu*. Portal de Datos Abiertos de Colombia. https://www.datos.gov.co/dataset/Datos-meteorol-gicos-Aranzazu/nqj3-4xmv/about_data

Almeida, A., Brás, S., Sargento, S., & Pinto, F. C. (2024). Focalize K-NN: an imputation algorithm for time series datasets. *Pattern Analysis and Applications*, *27*(39). https://doi.org/10.1007/s10044-024-01262-3

Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, *191*, 192-213.

Castro Benitez, G., & Torres Henao, K. D. (2026). *Focalize K-NN: Implementación y modelamiento en Python* [Repositorio de código fuente y control de versiones (Git/GitHub).]. https://github.com/GabrielCastroBenitez09/Proyecto-Machine-Learning1.git

Chicco, D., Warrens, M. J., & Jurman, G. (2021). The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *PeerJ Computer Science*, *7*, e623.

GitHub. (2026). *GitHub Copilot [Herramienta de asistencia de código basada en inteligencia artificial]* [Sugerencia de sintaxis y autocompletado en el desarrollo de scripts en Python.]. https://github.com/features/copilot

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, *6*(4), 15.

OpenAI. (2026). ChatGPT [Inteligencia artificial generativa].

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830.