




FOCALIZE K-NN

an imputation algorithm for time
series datasets



ARTÍCULO

Problema


Modelo y Supuestos

Resultados

Limitaciones

PROBLEMA

Pérdida de información en bases de datos con series de tiempo.




- Dificultad para analizar patrones temporales.
- Toma de decisiones desinformadas.

MODELO

SERIES DE
TIEMPO CON
FALTANTES

FEATURES
Y LAGS MÁS
RELACIONADOS




SERIES DE
TIEMPO
RECONSTRUIDAS

SUPUESTOS


Relaciones
entre Variables

Correlación
Temporal

Patrones de
Faltantes



PATRONES DE FALTANTES



Nota. Tomado de "Focalize K- NN: an imputation algorithm for time series datasets", Pattern Analysis and Applications, 27(39), p. 5.

RESULTADOS

OVERLAP


- Mejoras mínimas en comparación con K-NN tradicional.
- A partir de un 50% de faltantes: imputación por media/mediana presenta mejor desempeño.

DISJOINT

- Mejoras considerables en comparación con K-NN, Regresión Lineal e imputación por media/mediana.
- Buen desempeño con altos porcentajes de faltantes.



LIMITACIONES



■ **ESCALABILIDAD:** Al igual que K-NN, los dataset muy grandes representan un costo importante. El problema no desaparece solo con la reducción de predictores.

■ **FALTANTES ARTIFICIALES:** Los datos faltantes son generados artificialmente, por lo que los patrones considerados pueden no ser representativos de la realidad.

■ **SENSIBILIDAD AL PATRÓN DE LOS FALTANTES:** El modelo presenta diferencias significativas en su desempeño entre diferentes patrones de nulos.

PLANTEAMIENTO DEL PROBLEMA


Pregunta de
investigación

Variable objetivo

Relevancia en el
contexto colombiano


Objetivos

PREGUNTA DE INVESTIGACIÓN



■ ■ ■
¿FKNN recupera mejor los datos faltantes que K-NN tradicional?


Probamos diferentes niveles de datos faltantes



✓ VARIABLE OBJETIVO

NO EXISTE UNA ÚNICA ✓ VARIABLE OBJETIVO FIA

No existirá una única variable objetivo. Si se quiere saber el dato faltante de la temperatura imputamos la temperatura pero si se quiere saber la humedad imputamos la humedad




RELACION EN EL CONTEXTO COLOMBIANO

¿POR QUÉ ES IMPORTANTE?


Las estaciones pueden perder información por:

- Fallas eléctricas.
- Problemas de conectividad.
- Daños en sensores.
- Falta de mantenimiento.




RECUPERAR LOS DATOS PERMITE:

Conservar registros históricos.
Mejorar análisis climáticos.
Apoyar la agricultura.
Analizar sequías y heladas.
Mejorar la toma de decisiones.



OBJETIVO GENERAL

Reproducir y evaluar el algoritmo FKNN frente al algoritmo KNN para imputar datos faltantes en series temporales meteorológicas.



OBJETIVOS

OBJETIVOS ESPECIFICOS

Implementar
FKNN

Simular
patrones de
pérdida

Evaluar diferentes
niveles de pérdida

Comparar
metodos

ESTRATEGIA DE DATOS

Fuente

Caracterización

BASE DE DATOS REAL

CONTEXTO: Datos Meteorológicos


FUENTE: Datos Abiertos de Colombia

MUNICIPIO: Aranzazu - Caldas

PERÍODO: 2018 - 2019


FUENTE

MAPA: ROBERT EN ARANZAZU



Nota. Tomado de "Colombia - Caldas - Aranzazu.svg", por [Milenioscuro](#), Wikipedia.

CARACTERIZACIÓN



19190
REGISTROS

20
VARIABLES

18
VARIABLES
NUMÉRICAS

1
VARIABLE
TEMPORAL

1
VARIABLES
CATEGÓRICA

PLAN DE MODELANIENTO

Preparación de
los datos

Modelos
candidatos

Métrica de
evaluación

Linea Base

PREPARACIÓN DE LOS DATOS

COMO SE PREPARAN LOS DATOS

- Ordenar los registros cronológicamente.
- Convertir las variables al formato numérico cuando sea necesario.
- Trabajar sobre una base de datos originalmente completa.
- Generar artificialmente los datos faltantes



MODELOS CANDIDATOS

FKNN

Mediana

K-NN

Regresion
lineal

Media



MÉTRICA DE EVALUACIÓN

MAE

La métrica principal que vamos a utilizar es el MAE, que significa Error Absoluto Medio. Lo que hace es calcular, en promedio, qué tan lejos quedó cada valor imputado del valor real.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}|$$



LINEA BASE

MEDIA, MEDIANA Y REGRESION LINEAL

Media


→ Reemplazar faltantes por el promedio.

Mediana

→ Reemplazar faltantes por el valor central.

Regresión Lineal

→ Predecir el faltante mediante una relación lineal.



¡GRACIAS!



gabriel.castro2@est.uexternado.edu.co



karen.torres6@est.uexternado.edu.co

